Classificação Binária de Sentimentos em Reviews de Produtos Alimentares da Amazon: Uma Análise Comparativa

Afonso Abreu, Afonso Claudino, André Marques

Iscte - Instituto Universitário de Lisboa, Portugal

Resumo. O presente trabalho apresenta uma análise comparativa abrangente de diversas metodologias para a classificação binária de sentimentos (positivo ou negativo), aplicada a críticas de produtos alimentares da Amazon. O enquadramento experimental explora a evolução do Processamento de Linguagem Natural (NLP), abrangendo desde abordagens tradicionais baseadas em léxicos (NRC EmoLex) e aprendizagem automática estatística (Naive Bayes, SVM, Regressão Logística e Random Forest) até arquiteturas de última geração, incluindo Transformers (DistilBERT) e LLMs (GPT-4o). Foi dedicada especial atenção a estratégias de pré-processamento, tais como o tratamento de negação e técnicas de vectorização como TF-IDF e Word2Vec. Os resultados indicam que o modelo SVM, quando combinado com TF-IDF e tratamento de negação, alcança uma relação desempenho-eficiência altamente competitiva, revelando-se uma alternativa robusta para cenários de treino com poucos recursos. Contudo, o modelo GPT-4o obteve o melhor Macro F1-Score (0.93), com um conjunto de teste muito limitado, seguido de perto pelo DistilBERT com fine-tuning (0.92), demonstrando a capacidade dos modelos sensíveis ao contexto na captura das nuances linguísticas do feedback dos consumidores. Realçam-se os trade-offs entre o custo computacional e o rigor preditivo em diferentes paradigmas de modelação e concluímos que o DistilBERT com fine-tuning parece ser um modelo mais recomendado para a tarefa. O trabalho foi feito presencialmente por todos os membros do grupo, não sendo possível quantificar a contribuição de cada membro.

1 Introdução

A análise de sentimento constitui uma das áreas mais proeminentes do text mining, recorrendo a técnicas de Processamento de Linguagem Natural (NLP) para classificar automaticamente a polaridade afetiva de um conjunto de texto, geralmente positiva, negativa ou neutra.

No contexto atual, as plataformas de comércio eletrónico representam cerca de 20% do volume de vendas global, com exemplos de referência como o eBay, a Wish e o Alibaba. Entre estas, a Amazon destaca-se como a plataforma dominante, detendo aproximadamente 17% da quota de mercado mundial do e-commerce. A manutenção desta hegemonia exige um acompanhamento contínuo da satisfação dos clientes, tarefa para a qual a análise de sentimento sobre as avaliações de produtos se revela particularmente adequada.

O presente trabalho propõe uma avaliação comparativa de múltiplas abordagens de análise de sentimento aplicadas a um conjunto de dados composto por reviews de produtos alimentares da plataforma Amazon. As abordagens consideradas organizam-se em cinco categorias distintas: modelos baseados em léxicos e regras, nomeadamente TextBlob, VADER e Stanza; modelos baseados em transformadores, com recurso ao modelo distilbert-base-uncased-finetuned-sst-2-english; aplicação do léxico de sentimento EmoLex/NRC; treino de modelos de aprendizagem automática clássicos (SVM, Regressão Logística, Naive Bayes, Árvores de Decisão e Random Forest) com representações textuais obtidas via TF-IDF, Bag of Words e Word2Vec, complementados pelo modelo DistilBERT com fine-tuning; e modelos baseados em instrução, representados pelo GPT-4o da OpenAI.

2 Trabalho Relacionado

Gope et al. [1] apresentaram um estudo de análise de sentimento sobre reviews de produtos Amazon, comparando cinco algoritmos de aprendizagem automática com uma abordagem de deep learning. Em termos de modelos clássicos, foram avaliados SVM, Random Forest, Naïve Bayes Multinomial, Naïve Bayes Bernoulli e Regressão Logística, tendo o Random Forest obtido a melhor accuracy no conjunto de teste (0.92), com um F1-score de 0.95. Os autores aplicaram TF-IDF como método de representação das features e fizeram oversampling das classes minoritárias para mitigar o desequilíbrio do dataset. Para a abordagem de aprendizagem profunda, implementaram uma rede RNN, alcançando uma accuracy de 0.98 e concluindo que este modelo constitui a abordagem mais adequada para a análise. O trabalho demonstra que métodos baseados em deep learning superam claramente os classificadores clássicos quando aplicados a datasets de dimensão suficiente, mas não contempla abordagens léxicas não supervisionadas nem modelos baseados em Transformers pré-treinados.

Hawlader et al. [2] realizaram uma comparação entre três técnicas de extração de features (Bag of Words, TF-IDF e Word2Vec) cruzadas com seis modelos supervisionados: SVM, Naïve Bayes, Árvore de Decisão, Random Forest, Regressão Logística e Perceptrão Multicamada (MLP). O estudo utilizou um dataset de reviews de produtos eletrónicos da Amazon, balanceado com 24.000 exemplos por classe. Os resultados mostraram que o MLP com BOW obteve a melhor accuracy global (0.92), seguido de SVM com TF-IDF (0.90). A representação Word2Vec foi consistentemente inferior às restantes, com accuracy abaixo de 0.71, o que os autores atribuem à dimensão insuficiente do corpus para capturar adequadamente as relações semânticas entre palavras. O trabalho conclui que a escolha do método de vectorização tem um impacto tão significativo no desempenho final quanto a escolha do classificador, e que abordagens densas como Word2Vec requerem dados em maior volume para serem competitivas.

Lu [3] apresentou um estudo comparativo centrado na eficácia de duas técnicas de vectorização textual, TF-IDF e Word2Vec, no contexto da análise de sentimentos, utilizando o dataset Amazon Fine Food Reviews. Após o pré-processamento dos dados,

ambas as representações foram aplicadas a modelos de classificação para avaliar o seu desempenho. Os resultados demonstraram que o TF-IDF apresenta melhor capacidade de discriminação entre classes de sentimento, especialmente em datasets de maior dimensão, enquanto o Word2Vec se destaca na captura de relações semânticas entre palavras. O autor conclui que as duas abordagens possuem características complementares, sugerindo a sua combinação para melhorar o desempenho global dos sistemas de análise de sentimentos.

Tabany et al. [4] apresentaram um estudo sobre análise de sentimentos aplicado à deteção de reviews falsas na plataforma Amazon. Classificaram também a classificação sentimental das reviews, que é a parte mais relacionada com o nosso trabalho. Foram avaliados diversos classificadores, incluindo SVM, Naïve Bayes, Regressão Logística e Random Forest, tendo o modelo SVM apresentado o melhor desempenho na tarefa de classificação de polaridade, atingindo uma accuracy de cerca de 0.93. Quanto à deteção de reviews falsas, evidenciaram que padrões linguísticos e emocionais podem também ser úteis para as identificar.

Ali et al. [5] realizaram um estudo abrangente de análise de sentimentos sobre reviews da Amazon, comparando vários modelos. No pré-processamento textual, usaram técnicas como normalização e tokenização, seguidas de extração de características utilizando BOW e TF-IDF. Os autores avaliaram vários classificadores tradicionais, incluindo Naïve Bayes, Random Forest, Árvore de Decisão e Regressão Logística. Para além disso, exploraram modelos de deep learning, como CNN e BiLSTM, e modelos Transformer, nomeadamente BERT e XLNet.

Os autores concluíram que modelos baseados em Transformers obtêm o melhor desempenho global, com o BERT a atingir aproximadamente 0.89 de accuracy. Ainda assim, os autores verificaram que abordagens tradicionais com TF-IDF continuam a apresentar resultados competitivos e menor custo computacional.

Maurya e Pratap [6] desenvolveram um sistema de análise de sentimentos aplicado a reviews de produtos Amazon, recorrendo a técnicas supervisionadas clássicas de machine learning. Para a classificação de sentimentos, os autores utilizaram algoritmos supervisionados como Naïve Bayes e SVM, avaliando a capacidade destes modelos para distinguir entre reviews positivas e negativas. O modelo SVM apresentou melhor desempenho, beneficiando da sua capacidade de encontrar fronteiras de separação eficazes em espaços de elevada dimensionalidade, característica comum em tarefas de classificação textual. Os resultados mostraram que, mesmo com representações tradicionais das reviews, é possível obter classificações eficazes de polaridade, demonstrando a robustez de métodos supervisionados clássicos para análise de sentimentos em dados de e-commerce.

3 Dados Utilizados

O presente estudo utilizou o corpus amazon_reviews, segmentado em conjuntos de treino e teste. O dataset compreende um total de 51.319 instâncias, das quais a vasta maioria (48.902) pertence ao conjunto de treino. Observou-se um desequilíbrio acentuado nas classes, estando 77% das observações etiquetadas como positive (77% no treino e 69% no teste).

A análise exploratória manual, complementada pela visualização da nuvem de palavras (Fig. 1), confirmou que o domínio dos dados se centra em produtos alimentares, com elevada frequência de termos como "flavor", "taste", "coffee" e "tea". Adicionalmente, a presença de termos como "dog" e "cat" revela que o corpus abrange também o segmento de alimentação animal.

Verificámos também que as várias reviews contêm resíduos de html como "
" ou mesmo urls, que não deverão ser considerados neste trabalho.

Fig. 1. Word Cloud do conjunto de dados (retiradas stopwords e palavras não relevantes)



4 Trabalho Realizado

4.1 Limpeza do Dataset

Relativamente ao pré-processamento geral, focámo-nos principalmente em remover o ruído do dataset, e para este efeito utilizámos Expressões Regulares de modo a retirar URLs, HTML, pontuação e números. Esta foi a limpeza geral utilizada na maioria dos modelos, com algumas exceções, que serão explicitamente justificadas na seguinte secção.

4.2 Aplicação de Modelos Existentes

Modelos Baseados em Léxicos e Regras.

Para a Baseline, testámos três modelos:

TextBlob. Este modelo atribui uma polaridade a cada review, de -1 a 1. [7] Como este trabalho utiliza uma classificação binária, considerámos que as reviews com polaridade 0 deveriam ser classificadas como *negative.* Uma vez que sabemos que o dataset é muito desbalanceado para o lado dos positivos e uma vez que temos esse conhecimento prévio sobre a composição do conjunto de teste, considerámos que seria uma má prática considerar a polaridade 0 positiva, já que estaríamos a melhorar as estatísticas dos modelos artificialmente, considerando também que, se numa review de um produto, existe um sinal tão pouco claro de sentimento positivo, estará mais próximo de uma review negativa.

VADER. Como o VADER beneficia da presença de pontuação [8], não a retirámos no pré-processamento, e continuámos a preservar a estrutura do texto. Assim como no caso do TextBlob, as reviews com polaridade 0 foram classificadas como *negative*.

Stanza. O pré-processamento foi o mesmo que para o VADER. O Stanza atribui o número 1 a reviews que prevê serem neutras.[9] Novamente, atribuímos essas reviews à classe negativa.

Modelos Baseados em Transformadores.

Usámos apenas um modelo baseado em transformadores (sem fine-tuning):

DistilBERT (SST2-english). Não houve qualquer trabalho adicional para testar este modelo para além de manter a pontuação nas reviews, uma vez que é um modelo pré-treinado [10] e que o seu fine-tuning de modelos baseados em transformadores será uma experiência diferente. Foi escolhido este modelo em específico por recomendação dos Professores.

4.3 Léxico de Sentimentos

Foram feitas várias experiências usando apenas o léxico NCR EmoLex [11], com o objetivo final de somar a polaridade total de todas as palavras presentes numa review e simultaneamente no léxico de forma a classificá-la.

Primeiro foi aplicado Case Folding às reviews, uma vez que os termos no léxico estão também em letra minúscula. Mesmo verificando que o EmoLex não está lematizado (ou pelo menos não totalmente para vários casos) o que pode ser confirmado, por exemplo, com a presença de “cheerful”, “cheerfulness”, “cheer” e “cheering”, decidimos que teríamos mais hipóteses de criar “matches” entre termos se estes fossem lematizados nas reviews, dado que se estivesse presente numa review o termo “cheered”, não lhe seria atribuído nenhum valor de polaridade mas, após ser lematizado, tornar-se-ia “cheer” que já se encontra no EmoLex, e seria-lhe atribuída polaridade positiva. Para isto, utilizámos o WordNetLemmatizer da biblioteca NLTK [12]. Esta função necessita, no entanto, de um POS tag para fazer a lematização de todos os termos que não sejam nomes (que é o default POS tag), por isso, com este objetivo, tokenizámos e fizemos o POS tagging com a função pos_tag também da NLTK. Com este pre-processing, fizemos três experiências:

EmoLex sem tratamento da negação.

Para cada termo de uma review que se encontrasse no EmoLex com tag positiva, seria somado o valor 1 ao total da polaridade da review, enquanto para termos com tag negativa, foi somado o valor -1. Assim, indiretamente, tratamos também das palavras que têm ambas as tags no léxico. Reviews com valor de polaridade total estritamente maior que 0 são previstas como "positive", as restantes como "negative".

EmoLex com tratamento de negação (2-word scope).

Neste caso, a estrutura é idêntica ao caso anterior, adicionando um sistema para tratar da negação. Após a lematização, cada review torna-se uma lista, que é ordenada, composta por todos os termos lematizados. Criamos um conjunto de termos de negação, como "no", "barely", "never", "cannot". Cada review é uma lista (logo, ordenada) que contém todos os seus termos. Assim, o sistema passa por correr, um a um, cada termo de uma review. Quando um termo faz parte do conjunto de termos de negação, atualizámos a constante *negation_active_until* que é igual ao índice do último termo de negação encontrado mais 2, de forma a termos forma de contabilizar durante as duas palavras seguintes na lista, se estão ou não sob efeito da negação. Se o índice de um termo for igual ou menor ao valor atual de *negation_active_until*, o seu valor de polaridade é invertido, ou seja, se "good" se encontrar até dois termos a seguir a um termo de negação, como "not", passa a ter polaridade -1, e se for "bad" passa a ter polaridade 1. Decidimos usar esta lógica para a negação, mas compreendemos que "not good" tem um sentimento muito mais negativo associado que "not bad" tem positivo. Poderíamos, alternativamente, ter optado por passar casos como o anterior para polaridade 0.

EmoLex com tratamento de negação (2-word scope) e valence shifting.

Este caso é igual ao anterior, mas em vez de, no caso em que uma palavra com polaridade positiva é negada ("not good"), o seu novo valor de polaridade é agora -1.27 vezes o valor de polaridade antiga. Decidimos fazer esta experiência, inspirados nos resultados de Hogenboom et al. (2011) [13], que observou ser o valor que atingia melhores resultados para a negação no dataset de reviews de filmes em que testaram os seus modelos, mesmo que estes sejam diferentes dos nossos.

4.4 Treino de Modelos de Aprendizagem Automática

Abordagens clássicas.

Após a abordagem baseada em léxico, explorou-se a utilização de modelos de aprendizagem supervisionada, onde há um treino com o conjunto de treino, usando a biblioteca sckit-learn [14].

Em todos os exemplos da secção, foi aplicado um fit_transform ao conjunto de treino e apenas transform ao conjunto de teste, aquando da vectorização BOW e TF-IDF.

Com o Multinomial Naïve Bayes, foram testadas três variações principais:

Naïve Bayes com TF-IDF e Bag-of-Words (BoW).

Para garantir uma comparação justa entre a frequência absoluta do BOW e a frequência relativa da TF-IDF, limitou-se o vocabulário às 5000 palavras mais frequentes

e aplicou-se a remoção de stopwords padrão da língua inglesa. O objetivo foi avaliar se a simples contagem de termos seria suficiente para classificar o sentimento ou se a ponderação pela raridade do termo traria benefícios no domínio das reviews alimentares.

Naïve Bayes com Bag-of-Words e Tratamento de Negação,

Para tentar captar a inversão de polaridade (uma das maiores limitações dos modelos BOW) implementou-se uma terceira experiência utilizando a técnica mark_negation da biblioteca NLTK. Diferente das experiências anteriores, o pipeline de limpeza foi reestruturado, com a remoção de pontuação adiada até após a fase de tokenização, uma vez que o algoritmo de negação depende de delimitadores (como pontos e vírgulas) para definir o alcance do sufixo _NEG.
Nesta configuração, as stopwords foram filtradas de forma personalizada para garantir que partículas de negação (como "not" e "never") não fossem eliminadas antes de processadas. Além disso, expandiu-se o limite de caraterísticas para 10.000 features, de forma a acomodar o crescimento do vocabulário gerado pelos novos tokens negados (diferenciando good de good_NEG).

Dando continuidade à exploração de modelos supervisionados, implementou-se a Regressão Logística, sendo aqui utilizada com o parâmetro class_weight='balanced' para mitigar o desequilíbrio entre as classes positiva e negativa no dataset. Foram testadas três representações de texto distintas:

Regressão Logística com BOW e TF-IDF.

As duas primeiras experiências replicaram as vectorizações de frequência absoluta BOW e ponderada TF-IDF com um limite de 5.000 features da Naive Bayes.

Regressão Logística com Word2Vec (Embeddings).

Esta experiência serviu para comparar o desempenho de embeddings com as vectorizações anteriores. Nesta abordagem, o modelo Word2Vec [15] foi treinado especificamente com os tokens das reviews do conjunto de treino utilizando uma arquitetura de vetores densos com 100 dimensões e uma janela de contexto de 5 palavras.
Dado que o Word2Vec gera vetores para palavras individuais, utilizou-se a técnica de Average Pooling para representar cada review completa: calculou-se o vetor médio de todos os termos presentes na review que possuíam correspondência no modelo treinado.

Árvore de Decisão com BOW e TF-IDF.

Testou-se a Árvore de Decisão utilizando as representações BOW e TF-IDF, principalmente para testar o desempenho da Random Forest. Para mitigar o risco de overfitting, fixou-se a profundidade máxima (max_depth=30). Esta restrição força o modelo a selecionar apenas as palavras com maior ganho de informação, ignorando detalhes demasiado específicos do conjunto de treino que poderiam não generalizar bem para novos dados. Também foi utilizado class_weight='balanced' com a mesma justificação anterior.

Random Forest.

O modelo Random Forest foi configurado com 100 árvores independentes (n_estimators=100), operando através da técnica de Bagging. Tal como na experiência anterior, estas foram aplicadas tanto a vetores BoW como TF-IDF. Foi usado class_weight='balanced'.

Por fim, explorou-se a utilização de Support Vector Machines através da implementação LinearSVC. Tal como nos modelos anteriores, aplicou-se a ponderação class_weight='balanced' para assegurar que a fronteira de decisão não fosse enviesada pela classe maioritária. As experiências com SVM dividiram-se em quatro vertentes:

SVM com BoW e TF-IDF.

Utilizando as representações de 5.000 features extraídas por BOW e TF-IDF, o objetivo foi avaliar a capacidade do SVM em maximizar a margem de separação entre reviews positivas e negativas. Não foram tomadas medidas diferentes às experiências anteriores.

SVM com Word2Vec (Embeddings).

O SVM foi treinado sobre os mesmos vetores Word2Vec (Average Pooling) das experiências anteriores.

SVM com TF-IDF e Tratamento de Negação.

A experiência mais avançada com este classificador envolveu a integração do tratamento de negação personalizado. Utilizou-se o pipeline de tokenização com mark_negation. Para esta tarefa, expandiu-se o vocabulário para 15.000 features, permitindo ao SVM tratar termos negados (como happy_NEG) como dimensões totalmente distintas no espaço vetorial.

Finetuning de modelo baseado em transformers

DistilBERT (fine-tuned).

Procedeu-se ao Fine-tuning do DistilBERT. O DistilBERT foi selecionado por ser uma versão destilada, mais leve e rápida do BERT original, retendo aproximadamente 97% do seu desempenho. [16] Uma vez que o DistilBERT é um encoder, utiliza mecanismos de self-attention. Isto permite que o modelo compreenda o significado de uma palavra com base em todo o contexto da frase, tanto à esquerda como à direita. Consequentemente, o tratamento de negação torna-se intrínseco ao modelo.

Em termos de configuração do pipeline, utilizou-se a biblioteca transformers da Hugging Face para converter o dataset num formato compatível e aplicou-se o DistilBertTokenizer. Este processo utiliza WordPiece tokenization, que decompõe palavras raras em subunidades, mitigando o problema de palavras fora do vocabulário. As sequências foram normalizadas através de padding e truncation para garantir uniformidade nas entradas do modelo. Em termos de finetuning, o modelo distilbert-base-uncased foi treinado durante 3 épocas, utilizando uma learning rate = 2e-5 e um weight decay de 0.01 para regularização, valores dentro da gama recomendada pelos seus

criadores. Escolhemos o DistilBERT ainda não treinado para comparar com o DistilBERT SST2 que foi já treinado anteriormente.

4.5 Utilização de Modelos Baseados em Instruções

Por último, foi explorado o paradigma dos LLMs, utilizando o modelo GPT-4o através da API iaedu.pt. Pretendemos avaliar como diferentes níveis de instrução e contexto influenciam a precisão do modelo em regime de Zero-shot e Few-shot Learning. Para garantir a viabilidade estatística e computacional, utilizámos um subconjunto balanceado de 50 reviews (25 positivas e 25 negativas). É um compromisso com o que foi possível fazer com os nossos meios, sabendo que terá impacto na capacidade comparativa destas experiências com as restantes. Foram testadas três estratégias de prompting:

Prompt Genérico (Zero-shot).

Nesta abordagem de controlo, o modelo recebeu uma instrução direta e minimalista para classificar o texto apenas como "positive" ou "negative". Esta experiência serviu de baseline para medir a capacidade intrínseca do modelo em compreender o sentimento sem qualquer contexto adicional.

O prompt utilizado foi: "You are a sentiment analyzer. Classify the review text as 'positive' or 'negative'.
Respond ONLY with one of the words: positive or negative."

Prompt com Especialização de Domínio (Zero-shot Domain).

Para fornecer um maior contexto, elaborou-se um prompt que atribui uma persona de especialista ao modelo. O contexto foi enriquecido com detalhes específicos do domínio alimentar da Amazon. Esta estratégia visou testar se a ativação de conhecimentos específicos do domínio no modelo resultaria numa maior sensibilidade a nuances críticas das reviews.

O prompt utilizado foi: "You are an expert in analyzing Amazon product reviews, especially food, beverages, supplements, and grocery products.
Users write about taste, quality, price, delivery, texture, nutritional value, and overall satisfaction.
Classify the review below as 'positive' or 'negative' considering the context of purchasing food products on Amazon.
Respond ONLY with one of the words: positive or negative."

Prompt de Poucos Exemplos (Few-shot Learning).

A configuração mais robusta envolveu a inclusão de exemplos reais extraídos do conjunto de treino. Foram selecionados seis exemplos balanceados (3 positivos e 3 negativos), permitindo ao modelo observar o padrão de classificação esperado antes de processar a review de teste.

O prompt foi: "You are a sentiment analyzer specialized in Amazon reviews.
Here are some classified examples:" (…) "Now classify the review below. Respond ONLY with 'positive' or 'negative'."

5 Resultados Obtidos

Table 1. Resultados das Experiências

Modelo	Acc.	F1 Pos	F1 Neg	Macro F1
TextBlob	0.77	0.85	0.52	0.68
Vader	0.79	0.86	0.57	0.71
Stanza	0.63	0.67	0.57	0.62
DistilBERT SST2-english	0.82	0.86	0.76	0.81
EmoLex, tokenization, casefolding, POS, lemmatization	0.72	0.82	0.38	0.60
EmoLex, tokenization, casefolding, POS, lemmatization, negation (2-word scope)	0.72	0.81	0.49	0.65
EmoLex, tokenization, casefolding, POS, lemmatization, negation (2-word scope, valence shifting)	0.72	0.81	0.49	0.65
Naïve Bayes, cf, stopwords, TF-IDF, 5K features	0.78	0.86	0.50	0.68
Naïve Bayes, cf, stopwords, BOW, 5K features	0.85	0.89	0.75	0.82
Naïve Bayes, cf, stopwords, BOW, 10K features, negation	0.85	0.89	0.76	0.83
Regressão Logística, stopwords, TF-IDF, 5K features, class_weight = balanced	0.84	0.88	0.77	0.83
Regressão Logística, stopwords, BOW, 5K features, class_weight = balanced	0.84	0.88	0.76	0.82
Regressão Logística, Word2Vec (Avg Pooling), Vector Size=100	0.81	0.85	0.73	0.79
Árvore de Decisão, stopwords, TF-IDF, 5K features, class_weight = balanced, max_depth = 30	0.74	0.80	0.64	0.72
Árvore de Decisão, stopwords, BOW, 5K features, class_weight = balanced, max_depth = 30	0.74	0.80	0.63	0.72
Random Forest, stopwords, TF-IDF, 5K features, class_weight = balanced, max_depth = 20, estimators = 100	0.83	0.87	0.73	0.80
Random Forest, stopwords, BOW, 5K features, class_weight = balanced, max_depth = 20, estimators = 100	0.82	0.87	0.71	0.79
SVM, stopwords, TF-IDF, 5K features, class_weight = balanced, max_iter = 2K	0.84	0.88	0.76	0.82
SVM, stopwords, TF-IDF, 15K features, class_weight = balanced, max_iter = 2K, negation	0.86	0.90	0.78	0.84
SVM, stopwords, BOW, 5K features, class_weight = balanced, max_iter = 2K	0.83	0.87	0.74	0.81
SVM, stopwords, Word2Vec (Avg Pooling), 5K features, class_weight = balanced, max_iter = 2K	0.81	0.85	0.73	0.79
DistilBERT (fine-tuning), AutoTokenizer, learning_rate=2e-5, train_batch_size=16, train_epochs=3	0.92	0.95	0.87	0.91
GPT-4o (Zero-shot Generic)	0.90	0.89	0.91	0.90
GPT-4o (Zero-shot Domain)	0.92	0.91	0.93	0.92
GPT-4o (Few-shot)	0.90	0.89	0.91	0.90

5.1 Análise e Discussão

Um dos aspetos que nos pareceu mais claro, antes de fazer qualquer análise, foi a necessidade de utilizar uma métrica que não a accuracy. Dado o nosso dataset ter muitas mais reviews positivas que negativas, a accuracy oculta o mau desempenho dos modelos a classificar a classe minoritária (neste caso, as reviews negativas). Devido ao espaço limitado, e à já grande dimensão da nossa tabela (Table 1), não apresentamos o recall e precision de cada classe, mas podemos usar como exemplo os resultados do TextBlob: Uma accuracy de 77% como baseline parece excelente à primeira vista e o modelo teve ótimos resultados na previsão de reviews positivas. Se olharmos para a classe negativa, tem uma precision de 0.74, muito próxima do 0.71 para a classe positiva, mas tem um recall de 0.39 (0.94 para a classe positiva). Isto quer dizer que o modelo não deteta a grande maioria dos negativos. Para além disto, se em vez de utilizarmos um modelo, previssemos que todas as reviews do conjunto de teste fossem positivas, acabávamos com uma accuracy de 70% (percentagem arredondada de reviews positivas no conjunto). Não sendo perfeita, considerámos que a Macro F1-Score é uma métrica mais honesta, dando igual importância aos resultados da classe minoritária como maioritária.

Para os modelos baseados em léxico e regras, o VADER, que foi criado principalmente para ter um bom desempenho com documentos de redes sociais, acabou por superar as nossas espectativas dentro da sua categoria, tendo o STANZA surpreendido, ao contrário, pelos seus maus resultados, dado que se trata de um modelo com base em redes neuronais. Uma das hipóteses que colocamos a este mau desempenho é que o STANZA pode ter aplicado a polaridade a cada review de forma muito mais conservadora, tendo atribuído polaridades 0 com muito mais frequência (que, na nossa solução, são etiquetadas como negative) que o VADER. Uma das provas que suporta o argumento encontra se nos resultados específicos da classe negativa de ambos: Para o VADER 0.78 precision e 0.44 recall (maioria dos negativos não são “detetados”) enquanto para o STANZA temos 0.44 precision e 0.82 recall (o STANZA considera quase tudo negativo). Verifica-se que estes modelos têm dificuldades a prever a classe negativa.

O modelo de soma de polaridade com o léxico NCR EmoLex teve um desempenho ainda mais fraco, o que era de esperar, uma vez que é uma solução bastante mais simples. O tratamento da negação teve um efeito claro na sua capacidade de classificar review negativas, passando de F1-Score de 0.38 para 0.49. Adicionalmente, a utilização da Valence shifting inspirada no estudo de Hogenboom et al não teve qualquer efeito nos resultados do modelo. Atribuímos isto ao facto do EmoLex ser um léxico que atribui uma polaridade binária às suas classes, não existindo palavras “mais positivas” que outras, ao contrário do léxico usado no trabalho referido. Assim, numa review, a diferença de polaridade total, o peso adicional atribuído a termos positivo sob efeito de negação é inconsequente (-0.27 valores de polaridade adicional por termo positivo negado face ao modelo sem este tratamento).

Nas abordagens clássicas de modelos a ser treinados, importa salientar o salto de qualidade de desempenho comparativamente aos modelos anteriores. A grande dimensão do conjunto de treino comparativamente ao teste ajudou, certamente, a criar

modelos com uma capacidade de previsão alta, assim como a utilização de class_weight = “balanced”, visto que esse peso adicional dado à classe minoritária foi sentido no aumento do F1-Score da classe negativa. O tratamento de negação melhorou ligeiramente os resultados em todos os modelos, mas o que merece mais destaque é o já alto desempenho de modelos com um tratamento simples dos dados, como o Naive Bayes com BOW. A grande falha do Naive Bayes com TF-IDF vem da própria forma como o modelo funciona (o TF-IDF normaliza a frequência de termos, enquanto o modelo é construído com a frequência discreta bruta de termos em mente, o que justifica o seu desempenho com o BOW) o que, em retrospetiva, parece tornar esta experiência desnecessária. Já para as experiências com o SVM, a vectorização TF-IDF funciona melhor que a BOW (neste caso, a normalização do TF-IDF é um aspeto positivo). O maior Macro F1-Score desta secção pertence ao SVM com TF-IDF e tratamento de negação, porém, é difícil atribuirmos este sucesso apenas ao tratamento dos dados, uma vez que triplicámos o número de features do modelo (para futuro trabalho, deveria ser posto à prova o sucesso da negação com 10K features, sendo assim comparável à experiência com Naive Bayes). Destacamos também a Regressão Logística com TF-IDF.

O modelo DistilBERT SST2 teve resultados competitivo com os modelos clássicos treinados na área específica dos dados, mas o finetuning do modelo DistilBERT original com o conjunto de treino demonstrou uma capacidade que consideramos impressionante de previsão, sendo batido apenas pela utilização de LLMs (no caso, GPT 4-o) com o Zero-shot Domain, tendo este sido testado para uma quantidade ínfima de reviews comparativamente aos restantes modelos.

Finalmente, acreditamos que a queda de desempenho da experiência GPT 4-o few-shot terá sido causada por um défice de qualidade no Prompt Engineering da mesma.

6 Conclusões

Embora seja clara a grande capacidade de LLMs (comerciais), em todo o tipo de tarefas, consideramos que a barreira à sua utilização com grandes volumes de dados sem um enorme orçamento (e mesmo com esse orçamento, mantêm-se limites de tempo impostos pelo fornecedor), torna este método inviável para a esmagadora maioria dos casos de classificação de dados volumosos. Concluímos, portanto, que, dentro dos modelos avaliados, o DistilBert com fine-tuning apresenta o melhor desempenho, tendo em conta o custo computacional, na classificação de sentimentos em reviews de produtos alimentares da Amazon. Ainda concluímos que os modelos de Machine Learning clássicos com treino, para este mesmo fim, conseguem manter-se competitivos, destacando o modelo SVM com TF-IDF e tratamento de negação (15K features) e a Regressão Logística com TF-IDF (5K features).

Para trabalho futuro, para além do que foi já mencionado na secção 5, recomendamos que seja testado o tratamento de negação para a Regressão Logística com TF-IDF, uma vez que acreditamos poder superar a experiência semelhante com o modelo SVM.

Recomendamos o desenvolvimento de novas experiências de fine-tuning com o modelo DistilBERT, o que poderá melhorar ainda mais o seu desempenho.

Seria importante, com as capacidades computacionais necessárias, testar o desempenho de versões de LLMs locais offline, uma vez que, caso tivessem um desempenho comparável às versões totais, tonaria viável a sua utilização.

Referências

1. Gope, J.C., Tabassum, T., Mabrur, M.M., Yu, K., Arifuzzaman, M.: Sentiment analysis of Amazon product reviews using machine learning and deep learning models. In: 2022 International Conference on Advancement in Electrical and Electronic Engineering (ICAEEE)
2. Hawlader, M., Ghosh, A., Raad, Z.K., Chowdhury, W.A., Shehan, M.S.H., Ashraf, F.B.: Amazon product reviews: Sentiment analysis using supervised learning algorithms. In: 2021 International Conference on Electronics, Communications and Information Technology (ICECIT), pp. 1–6. IEEE (2021)
3. Lu, J.: Text vectorization in sentiment analysis: A comparative study of TF-IDF and Word2Vec from Amazon Fine Food Reviews. ITM Web of Conferences, vol. 70, 03001. EDP Sciences (2025). DOI: 10.1051/itmconf/20257003001
4. Tabany, M., Gueffal, M.: Sentiment Analysis and Fake Amazon Reviews Classification Using SVM Supervised Machine Learning Model. Journal of Advances in Information Technology, vol. 15, no. 1, pp. 49–58 (2024). DOI: 10.12720/jait.15.1.49-58
5. Ali, H., Hashmi, E., Yildirim, S.Y., Shaikh, S.: Analyzing Amazon Products Sentiment: A Comparative Study of Machine Learning, Deep Learning, and Transformer-Based Techniques. Electronics, vol. 13, no. 7, 1305 (2024)
6. Maurya, R., Pratap, A.: Sentiment Analysis on Amazon Product Reviews. International Journal of Computer Science and Engineering, vol. 6, no. 5, pp. 998–1003 (2018)
7. Loria, S. (2018). TextBlob: Simplified Text Processing. [Online]. Disponível em: https://textblob.readthedocs.io/
8. Hutto, C. J., & Gilbert, E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. In Proceedings of the Eighth International Conference on Weblogs and Social Media (ICWSM-14)
9. Qi, P., Zhang, Y., Zhang, Y., Bolton, J., & Manning, C. D. (2020). Stanza: A Python Natural Language Processing Toolkit for Many Human Languages
10. Hugging Face: distilbert-base-uncased-finetuned-sst-2-english. Hugging Face Hub (2024). DOI: 10.57967/hf/0181. Disponível em: Hugging Face model page
11. Mohammad, S. M., & Turney, P. D. (2013). Crowdsourcing a Word-Emotion Association Lexicon. Computational Intelligence, 29(3), 436-465
12. Bird, S., Klein, E., & Loper, E. (2009). Natural Language Processing with Python. O'Reilly Media, Inc.
13. Hogenboom, A.; van Iterson, P.; Heerschop, B.; Frasincar, F.; Kaymak, U. Determining negation scope and strength in sentiment analysis. 2011 IEEE International Conference on Systems, Man and Cybernetics - SMC. LOCATION OF CONFERENCE, United StatesDATE OF CONFERENCE; pp. 2589–2594.
14. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830
15. Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space
16. Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter